

# Predicción de homicidios por arma de fuego mediante la implementación de redes neuronales

*Ricardo Abdiel Santana Ruiz<sup>1</sup>*

*Asesor: Sergio Iván Valdez Peña<sup>2</sup>*

*CUCEI, Universidad de Guadalajara,*

*abdiel.santana@alumnos.udg.mx<sup>1</sup>*

*Centro de Investigación en Geografía y Geomática Ing. Jorge L. Tamayo, A.C.(CONACYT),*

*svaldez@centrogeo.edu.mx<sup>2</sup>*

## Resumen

Realizar predicciones de homicidios dolosos por arma de fuego mediante el uso de redes neuronales en las zonas metropolitanas más importantes de México. Se utilizaron los datos abiertos del Secretario Ejecutivo sobre la incidencia delictiva del país y se eligieron los 20 delitos con más correlación con los homicidios por arma de fuego como variables de entrada para hacer predicciones para los años 2019 y 2020 y ver la precisión con la que se daba la predicción.

## Introducción

La delincuencia es uno de los problemas más grandes a los cuales se enfrenta en México, y delitos tales como los homicidios dolosos han ido en alza en los últimos años, siendo los homicidios dolosos por arma de fuego nuestro principal interés en este trabajo para hacer una predicción mediante el uso de redes neuronales.

La sociedad mexicana se ha ido acostumbrando cada vez más a la violencia y parece que las medidas que el gobierno ha utilizado en los últimos años no han sido del todo efectivo, por lo que se espera que los resultados de este trabajo sirvan como base para planificación y prevención efectiva de medidas en contra de estos homicidios por arma de fuego para el futuro.

Se tomó como guía de desarrollo el tomar delitos con mayor correlación con respecto a la

variable que queremos predecir (homicidios por arma de fuego) para así poder elegir nuestras variables de entradas para poder hacer predicciones mediante el uso de redes neuronales, pero se espera mejorar los resultados obtenidos al hacer diferentes pruebas con distintos acercamientos en el futuro.

## Metodología

Se hizo uso de los Datos Abiertos de Incidencia Delictiva dados por el gobierno en la liga <https://www.gob.mx/sesnsp/acciones-y-programas/datos-abiertos-de-incidencia-de-state=published>, en particular las Cifras de Incidencia Delictiva Municipal que van de enero de 2015 a mayo de 2020 para tener una visión más precisa de los lugares con mayor incidencia delictiva. Se hicieron uso de los datos de julio de 2016 hasta abril de 2020 debido a que se en-

cuentra una discrepancia muy grande entre los datos registrados de robos desde 2015 hasta julio de 2016 sin ninguna razón aparente mas que elecciones gubernamentales en ciertos estados de la república pero que siguen sin explicar la alza tan grande de robos y su *tendencia* constante en los años a seguir, además de que solo se tenía registro de los datos hasta el mes de mayo de 2020 hasta la fecha cuando se realizó el proyecto.

La primera etapa de este proyecto fue la recolección y filtro de datos, de donde se utilizaron en un principio los datos de la Zona Metropolitana de Guadalajara (ZMG) para hacer pruebas iniciales sobre esta zona y ver los resultados que obteníamos para después aplicar este mismo procedimiento para más zonas metropolitanas y municipios del país. Así, se hicieron varios archivos *.csv* con los datos para cada año (2015, 2016, 2017, 2018, 2019, 2020) de los municipios de la ZMG.

Una vez obtenidos los datos de estos municipios, se procedió a filtrar por las subtipos de delitos y sus modalidades con el fin de tener la mayor precisión posible con los datos con el uso de la librería **Pandas** de Python [1]. Así, se agrupó cada modalidad de delito para no repetir los datos para cada estado y, con esto, tendríamos nuestros primeros datos que empezaríamos a preprocesar para utilizarlos en la red neuronal.

Para la siguiente etapa se calcularon las correlaciones con el método de *spearman* (mediante el uso de la librería **Scipy** de Python)[2] entre delitos con respecto a los homicidios dolosos por arma de fuego, estos últimos delitos siendo incluidos una segunda vez pero en esta ocasión estando adelantados por un mes, dos meses y tres meses con respecto a los otros delitos; esto es, empezábamos con nuestros delitos del año 2016 en enero mientras que los datos de homicidios por arma de fuego empezaron en febrero, abril y marzo de ese mismo año. Con esta información se hizo un mapa de calor con la librería **Seaborn**[3] para una mejor representación de las correlaciones, enfocándonos en particular en la

correlación que tenían los homicidios con arma de fuego adelantado por uno, dos y tres meses con respecto a los demás, ordenándolos de mayor a menor.

En esta etapa empezamos a hacer una selección más específica de los datos para nuestra red neuronal, pues pudimos notar que es a partir de los tres meses de diferencia cuando las correlaciones se empiezan a hacer menores, tanto positivas como negativas, por lo que nos quedamos con los datos que estaban adelantados por uno y dos meses. Después, seleccionamos el 25 % de los delitos con correlación más positiva y 25 % de los delitos con correlación más negativa. Una vez hecho esto, contamos las veces que aparecían cada delito en cada año y finalmente se tomaron los 20 delitos que más se repetían. Los delitos utilizados para nuestra red neuronal y su número de delito respectivo se puede encontrar en el apéndice A.

Una vez llegada a esta parte, se procedió a entrenar una red neuronal ahora con la librería **neuralnet** de RStudio [4] con estos datos y se comenzaron a hacer predicciones, tomando como datos de entrenamiento desde junio de 2016 hasta diciembre de 2018 y dejando de enero de 2019 a mayo de 2020 como nuestros datos para hacer las pruebas de la red. Así, se hicieron predicciones para los municipios más importantes (desde 4 a 6) de las 5 zonas metropolitanas más importantes del país con siete redes neuronales con distintos números de capas y de neuronas dentro de estas capas. Para escoger las redes neuronales que presentaríamos se calculó el error absoluto medio entre los valores predichos y los valores reales para después graficar estos errores a través de los meses predichos y ver cuál era la red que nos daba errores más bajos en general. Las gráficas obtenidas se pueden encontrar en el Apéndice B.

# Resultados

Después de ver los errores que nos generaba cada red, se escogieron las 3 que nos dieron mejores resultados en general, las cuales tenían un arreglo de capas de (1, 20, 80, 180, 1), (80, 40, 20, 10, 1) y (40, 20, 10, 7, 5) y errores mínimos y máximos de 1.661904 y de 9.748412 para el primer modelo, 1.661877 y 7.980742 para el segundo modelo y 1.907095 y 8.057179 para el tercer modelo, respectivamente para los 5 cinco municipios elegidos (Guadalajara, Puebla, Monterrey, Ecatepec de Morelos y Toluca), dando predicciones cercanas a los valores reales.

Finalmente, se hicieron mapas con la ayuda del paquete `tmap` [5] con los datos reales y otros con los datos predichos por las redes para los meses de enero, febrero, marzo, abril, mayo y junio. A continuación se presentan los mapas obtenidos para los datos reales de homicidios por arma de fuego y los predichos por las tres redes neuronales. Se anexan los datos de estas predicciones y los valores reales en una tabla en el Apéndice C.

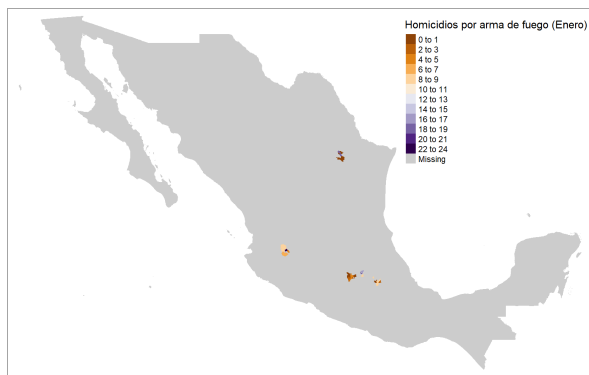


Figura 1: Mapa de los datos reales de homicidios por arma de fuego para enero de 2020.

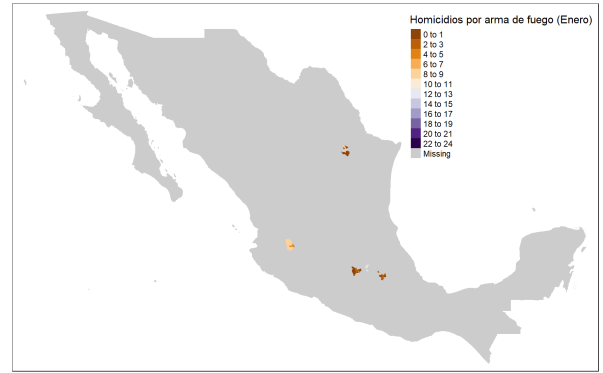


Figura 2: Mapa de los datos predichos por la primera red de homicidios por arma de fuego para enero de 2020.

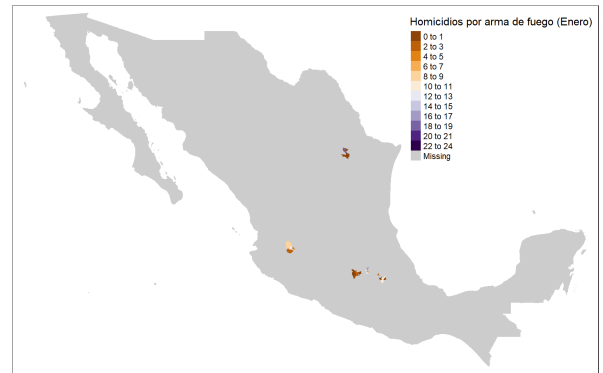


Figura 3: Mapa de los datos predichos por la segunda red de homicidios por arma de fuego para enero de 2020.

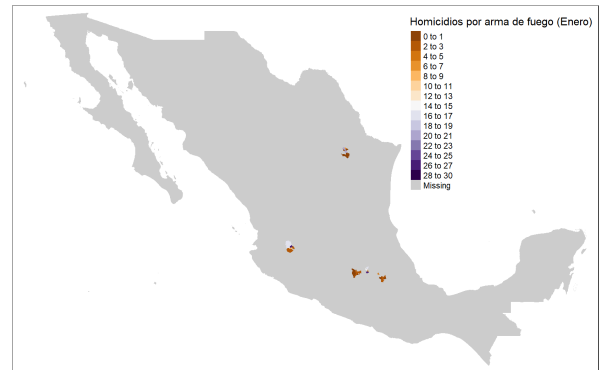


Figura 4: Mapa de los datos predichos por la tercera red de homicidios por arma de fuego para enero de 2020.

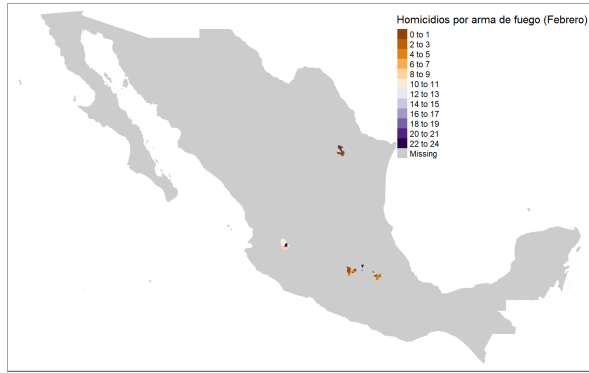


Figura 5: Mapa de los datos reales de homicidios por arma de fuego para febrero de 2020.

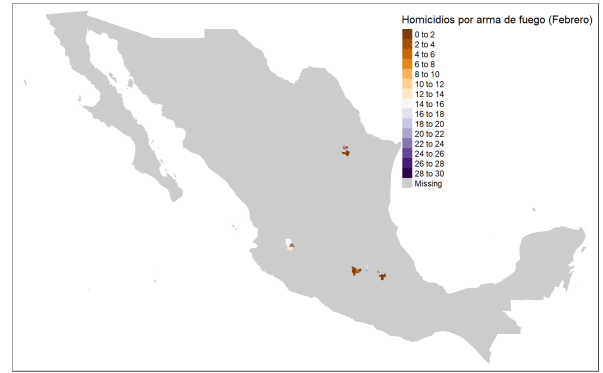


Figura 8: Mapa de los datos predichos por la tercera red de homicidios por arma de fuego para febrero de 2020.

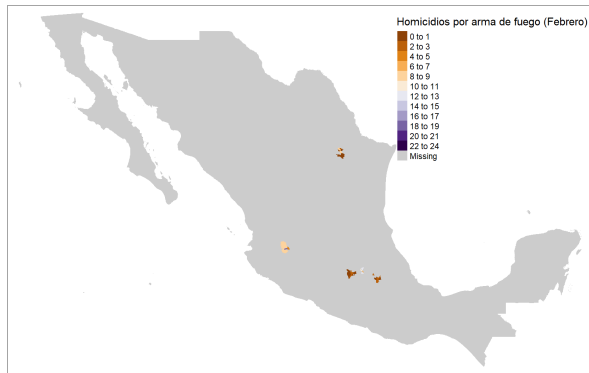


Figura 6: Mapa de los datos predichos por la primera red de homicidios por arma de fuego para febrero de 2020.

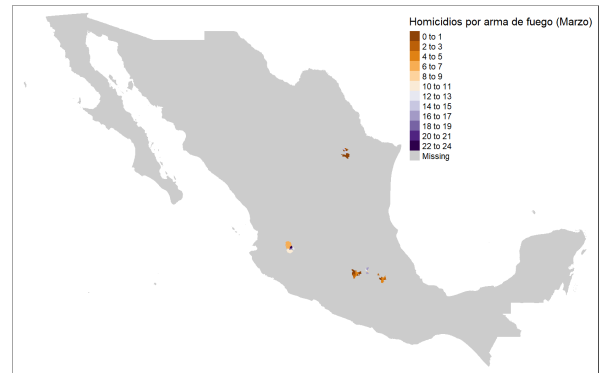


Figura 9: Mapa de los datos reales de homicidios por arma de fuego para marzo de 2020.

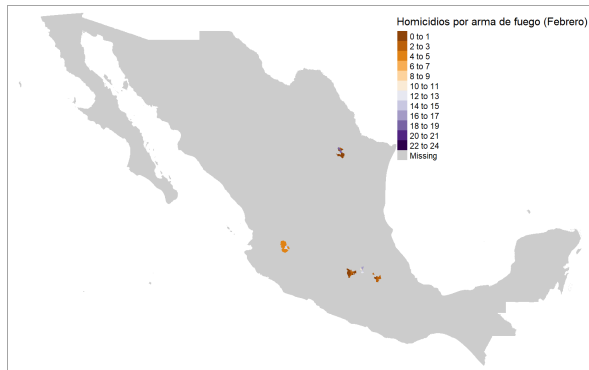


Figura 7: Mapa de los datos predichos por la segunda red de homicidios por arma de fuego para febrero de 2020.

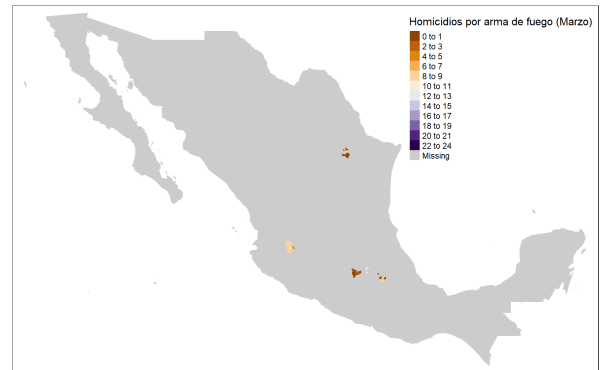


Figura 10: Mapa de los datos predichos por la primera red de homicidios por arma de fuego para marzo de 2020.

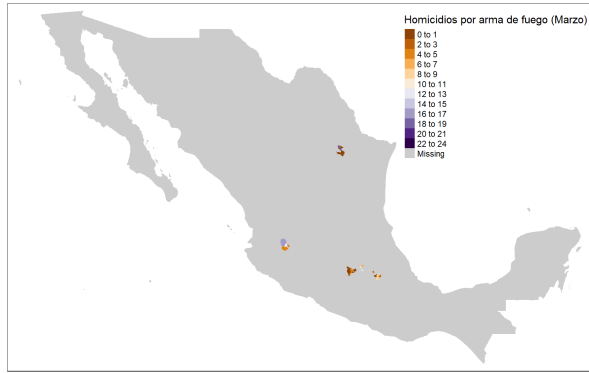


Figura 11: Mapa de los datos predichos por la segunda red de homicidios por arma de fuego para marzo de 2020.

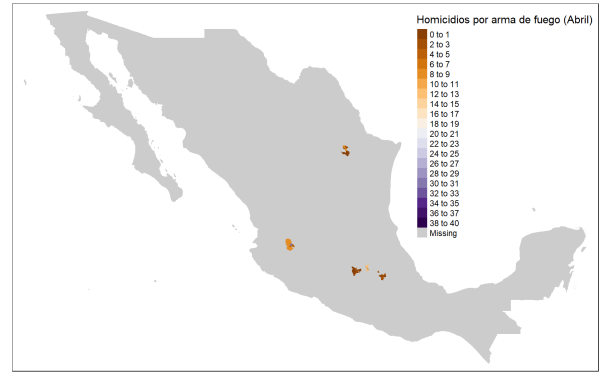


Figura 14: Mapa de los datos predichos por la primera red de homicidios por arma de fuego para abril de 2020.

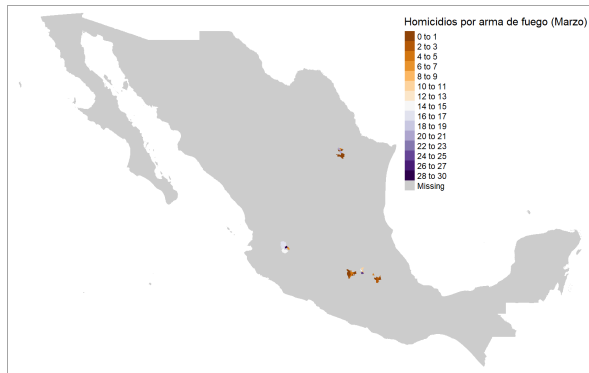


Figura 12: Mapa de los datos predichos por la tercera red de homicidios por arma de fuego para marzo de 2020.

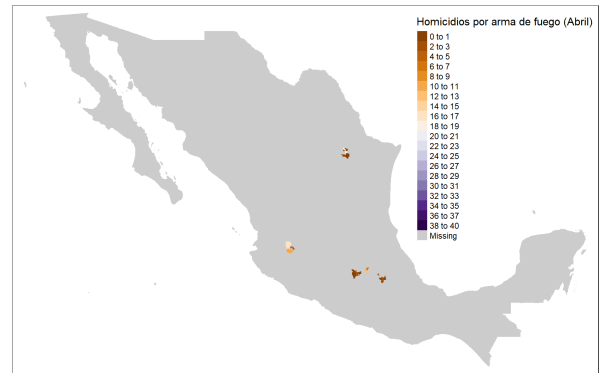


Figura 15: Mapa de los datos predichos por la segunda red de homicidios por arma de fuego para abril de 2020.

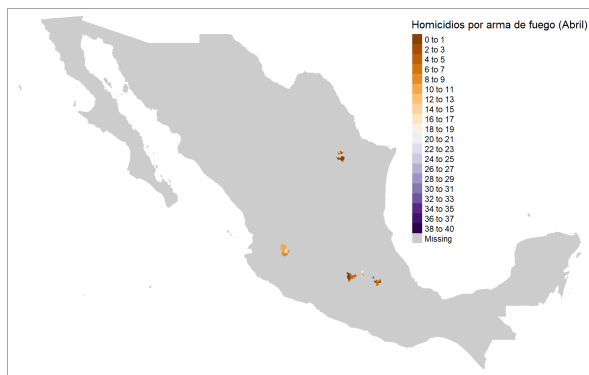


Figura 13: Mapa de los datos reales de homicidios por arma de fuego para abril de 2020.

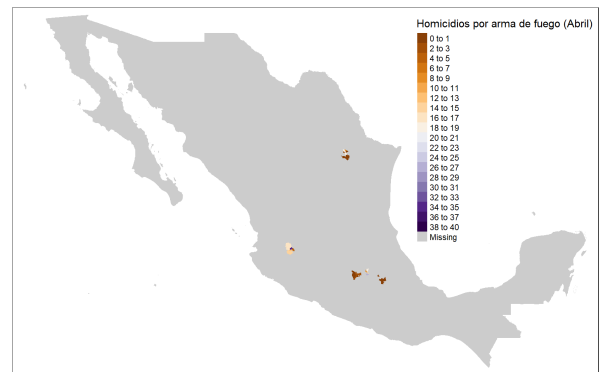


Figura 16: Mapa de los datos predichos por la tercera red de homicidios por arma de fuego para abril de 2020.

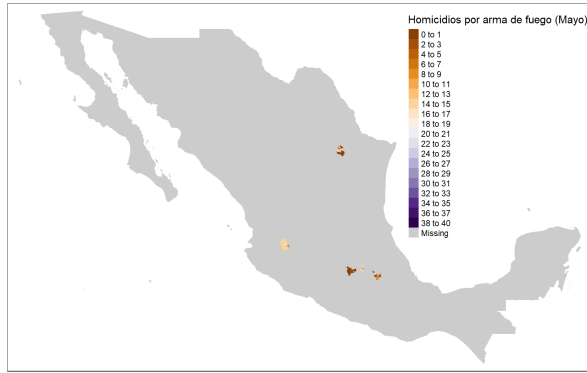


Figura 17: Mapa de los datos reales de homicidios por arma de fuego para mayo de 2020.

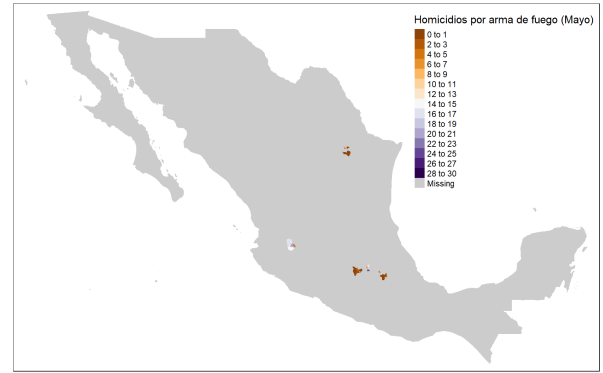


Figura 20: Mapa de los datos predichos por la tercera red de homicidios por arma de fuego para mayo de 2020.

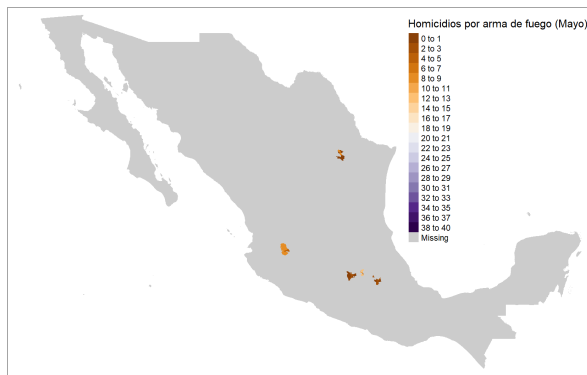


Figura 18: Mapa de los datos predichos por la primera red de homicidios por arma de fuego para mayo de 2020.

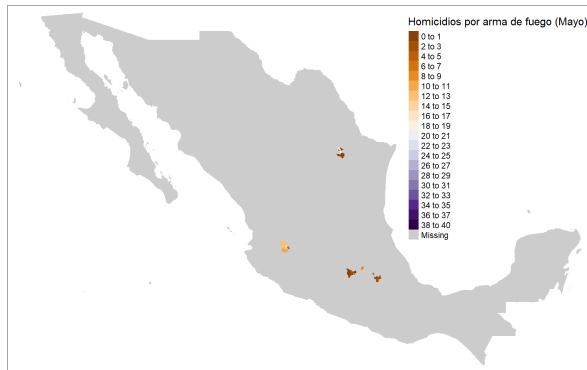


Figura 19: Mapa de los datos predichos por la segunda red de homicidios por arma de fuego para mayo de 2020.

## Discusiones

Los resultados obtenidos son muy cercanos a los datos reales en varios de los municipios analizados en 2020, sin embargo, es difícil determinar para este año si los errores en la predicción de las redes neuronales son debidos a la situación del COVID-19 que estamos viviendo pues ha afectado en gran medida la forma en que llevamos nuestra vida cotidiana, afectando de igual forma la incidencia delictiva.

Algo que debe hacerse notar es que las redes neuronales fallaban a la hora de hacer predicciones cuando se aplicaba a municipios que tenían una cantidad muy baja de homicidios por arma de fuego durante los años analizados. Esto sucedía principalmente en municipios que tenían poblaciones pequeñas comparadas a ciudades más grandes o en zonas rurales. Estos errores podrían ser corregidos al escoger nuevas variables de entrada según si se trata de una población rural o urbana y sus municipios aledaños.

Una última cosa por notar es la aleatoriedad de los delitos, algo que podría explicar el hecho que las redes tengan predicciones muy acertadas en algunas ocasiones y otras un tanto alejadas en otras. Un objetivo a tener en cuenta es ver si nuestra red es capaz de detectar estos picos que podrían presentarse a lo largo del año, tal

vez debido a un evento importante en el país o en la zona específica de donde se trata de hacer la predicción, pero tampoco se descarta la idea de que los datos puedan ser manipulados o mal registrados por parte del gobierno, pues como se discutió al principio de este reporte, se tiene registro de una alza inexplicada de delitos sin ningún antecedente o justificación y que se mantendría de esa forma a lo largo de los demás años.

## Conclusiones

El hacer uso de las correlaciones entre delitos para tomar predictores para el entrenamien-

to de nuestra red neuronal resultó ser un método efectivo para nuestro objetivo de este proyecto, pues daba valores cercanos a los reales, por lo que se espera poder tener mejores resultados haciendo uso de distintas técnicas y manipulando características de la red para así obtener errores menores en nuestras predicciones.

## Notas

Los archivos, así como los programas utilizados para el desarrollo de este proyecto se pueden encontrar en un repositorio de GitHub en la liga <https://github.com/RASR-dot/Proyecto-Delfin>. [6]

## 1. Apéndice A

### Delitos utilizados como predictores

# de delito	Nombre del delito	# de delito	Nombre del delito
02	Abuso de confianza	52	Otros robos sin violencia
05	Allanamiento de morada	55	Robo a casa habitación sin violencia
06	Amenazas	59	Robo a negocio sin violencia
14	Extorsión	62	Robo a transeúnte en vía pública al público con violencia
23	Homicidio culposo con arma de fuego	64	Robo a transportista con violencia
34	Lesiones culposas con arma blanca	69	Robo de ganado sin violencia
37	Lesiones culposas en accidente de tráfico	72	Robo de herramienta industrial o agrícola con violencia
42	Lesiones dolosas no especificado	77	Robo de coche de 4 ruedas sin violencia
43	Narcomenudeo	91	Secuestro extorsivo
48	Otros delitos que atentan contra la libertad personal	98	Violencia familiar

Cuadro 1: Tabla de delitos utilizados para el entrenamiento de la red neuronal

## 2. Apéndice B

### Error absoluto medio para los distintos modelos utilizados




Figura 21: Error absoluto medio para Monterrey.




Figura 24: Error absoluto medio para Toluca.




Figura 22: Error absoluto medio para Guadalajara.




Figura 25: Error absoluto medio para Ecatepec de Morelos.




Figura 23: Error absoluto medio para Puebla.



### 3. Apéndice C

## Predicciones y errores obtenidos por las redes para los municipios utilizados

### Gustavo A. Madero (09005)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	18	11	11	15
Febrero	10	11	11	13
Marzo	12	11	11	15
Abril	12	11	11	8
Mayo	13	11	11	7

Modelo 1	Modelo 2	Modelo 3
2.3108295757	2.3031547706	3.8993809904

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Gustavo A. Madero.

### Iztapalapa (09007)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	8	13	13	26
Febrero	16	13	13	20
Marzo	16	13	13	26
Abril	15	13	13	26
Mayo	16	13	13	25

Modelo 1	Modelo 2	Modelo 3
2.9465784358	2.9391672690	10.525857898

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Iztapalapa.

### Guadalajara (14039)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	23	9	12	26
Febrero	23	9	15	22
Marzo	33	9	13	29
Abril	18	31	30	34
Mayo	17	9	16	21

Modelo 1	Modelo 2	Modelo 3
14.958087866	10.278604638	5.6759984943

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Guadalajara.

## Tlajomulco (14097)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	7	8	3	2
Febrero	8	8	5	13
Marzo	10	8	5	14
Abril	9	8	10	15
Mayo	14	8	10	14

Modelo 1	Modelo 2	Modelo 3
1.985712423	3.5886223364	4.0315624668

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Tlajomulco.

## Tlaquepaque (14098)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	15	5	12	9
Febrero	21	19	12	23
Marzo	19	10	12	19
Abril	17	5	12	12
Mayo	13	4	12	20

Modelo 1	Modelo 2	Modelo 3
8.4819804544	5.449796783	4.0608066105

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Tlaquepaque.

## Tonalá (14101)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	5	5	5	3
Febrero	13	5	5	5
Marzo	12	5	5	7
Abril	9	5	5	5
Mayo	8	5	5	4

Modelo 1	Modelo 2	Modelo 3
4.1008093092	4.1014757094	4.5286640270

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Tonalá.

## Zapopan (14120)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	8	8	9	16
Febrero	11	8	4	15
Marzo	7	8	16	16
Abril	10	8	16	16
Mayo	14	8	13	16

Modelo 1	Modelo 2	Modelo 3
2.3340249622	4.9043826585	6.0062490386

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Zapopan.

## Almoloya de Juárez (15005)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	1	1	0	0
Febrero	1	1	0	0
Marzo	0	1	0	0
Abril	1	1	0	1
Mayo	1	1	0	0

Modelo 1	Modelo 2	Modelo 3
0.47832949239	0.69770614154	0.65749113461

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Almoloya de Juárez.

## Ecatepec de Morelos (15033)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	17	13	17	16
Febrero	23	13	16	16
Marzo	17	13	6	11
Abril	20	13	7	18
Mayo	15	13	6	13

Modelo 1	Modelo 2	Modelo 3
5.7969226361	7.9463048111	3.7331843170

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Ecatepec de Morelos.

## Lerma (15051)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	0	0	0	2
Febrero	0	0	0	0
Marzo	0	0	0	0
Abril	4	0	0	2
Mayo	1	0	0	1

Modelo 1	Modelo 2	Modelo 3
1.0941256330	1.092134355	1.094049104

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Lerma.

## Metepec (15054)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	2	0	0	0
Febrero	0	0	0	0
Marzo	0	0	0	0
Abril	2	0	0	0
Mayo	0	0	0	0

Modelo 1	Modelo 2	Modelo 3
0.85569501272	0.85237211388	0.85307794335

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Metepec.

## Nezahualcóyotl (15058)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	7	8	3	2
Febrero	8	8	5	13
Marzo	10	8	5	14
Abril	9	8	10	15
Mayo	14	8	10	14

Modelo 1	Modelo 2	Modelo 3
0.89105150811	6.6948019267	5.432068783

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Nezahualcóyotl.

## Toluca (15106)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	5	3	2	2
Febrero	7	3	2	4
Marzo	5	3	5	5
Abril	6	3	2	2
Mayo	2	3	2	3

Modelo 1	Modelo 2	Modelo 3
2.5438323177	2.5233395063	2.3563848608

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Toluca.

## Zinacantepec (15118)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	2	0	0	0
Febrero	2	0	0	0
Marzo	2	0	0	0
Abril	0	0	0	0
Mayo	0	0	0	0

Modelo 1	Modelo 2	Modelo 3
1.1950611904	1.1052168438	1.1989985665

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Zinacantepec.

## San Pedro Garza García (19019)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	0	1	1	1
Febrero	0	1	0	0
Marzo	0	1	1	1
Abril	0	1	1	0
Mayo	0	1	4	4

Modelo 1	Modelo 2	Modelo 3
0.76057283651	1.4100484714	1.2495940910

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de San Pedro Garza García.

## Guadalupe (19026)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	0	1	1	1
Febrero	0	1	1	1
Marzo	0	1	1	1
Abril	0	1	1	1
Mayo	0	1	1	1

Modelo 1	Modelo 2	Modelo 3
0.99990258739	0.99989667559	0.99989893357

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Guadalupe.

## Monterrey (19039)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	19	9	18	20
Febrero	20	9	18	21
Marzo	14	9	18	20
Abril	13	9	18	19
Mayo	12	9	18	19

Modelo 1	Modelo 2	Modelo 3
6.8429425015	3.6095613920	4.1953612509

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Monterrey.

## San Nicolás de los Garza (19046)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	0	2	2	6
Febrero	1	2	2	7
Marzo	2	2	2	6
Abril	3	2	2	9
Mayo	1	2	2	8

Modelo 1	Modelo 2	Modelo 3
0.9059084358	0.9071926788	5.6226161816

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de San Nicolás de los Garza.

## Santiago (19049)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	0	0	0	0
Febrero	0	0	0	0
Marzo	0	0	0	0
Abril	1	0	0	0
Mayo	0	0	0	0

Modelo 1	Modelo 2	Modelo 3
0.49994102366	0.49537042989	0.34182806131

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Santiago.

## Amozoc (21015)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	2	1	0	1
Febrero	3	1	2	2
Marzo	2	1	2	0
Abril	0	1	0	0
Mayo	0	1	2	3

Modelo 1	Modelo 2	Modelo 3
1.253200350	1.0753935393	1.2215297820

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Amozoc.

## Cuautlancingo (21041)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	0	0	0	0
Febrero	0	0	0	0
Marzo	0	0	0	0
Abril	1	0	0	0
Mayo	0	0	0	0

Modelo 1	Modelo 2	Modelo 3
0.41952426152	0.41996678843	0.22303487677

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Cuautlancingo.

## Puebla (21114)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	9	2	10	2
Febrero	5	2	2	1
Marzo	4	8	8	2
Abril	6	2	2	1
Mayo	8	2	2	1

Modelo 1	Modelo 2	Modelo 3
4.8436153115	3.6246292242	4.787163354

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de Puebla.

## San Andrés Cholula (21119)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	1	0	0	0
Febrero	2	0	0	0
Marzo	0	0	0	0
Abril	0	0	0	0
Mayo	1	0	0	0

Modelo 1	Modelo 2	Modelo 3
0.8	0.8	0.8

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de San Andrés Cholula.

## San Martín Texmelucan (21132)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	8	2	2	4
Febrero	2	2	2	4
Marzo	3	2	2	4
Abril	1	2	2	1
Mayo	2	2	2	4

Modelo 1	Modelo 2	Modelo 3
1.6106170154	1.60780367342	1.8495367078

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de San Martín Texmelucan.



## San Pedro Cholula (21140)

Mes	Real	Modelo 1	Modelo 2	Modelo 3
Enero	1	0	0	0
Febrero	0	0	0	0
Marzo	0	0	0	0
Abril	0	0	0	0
Mayo	0	0	0	0

Modelo 1	Modelo 2	Modelo 3
0.2	0.2	0.2

Tablas de las predicciones obtenidas por las redes neuronales (izquierda) y del error absoluto medio de cada red (derecha) para el municipio de San Pedro Cholula.

## Referencias

- [1] The pandas development team.  
pandas-dev/pandas: Pandas, February 2020.
- [2] Pauli Virtanen, Ralf Gommers, Travis E. Oliphant, Matt Haberland, Tyler Reddy, David Cournapeau, Evgeni Burovski, Pearu Peterson, Warren Weckesser, Jonathan Bright, Stéfan J. van der Walt, Matthew Brett, Joshua Wilson, K. Jarrod Millman, Nikolay Mayorov, Andrew R. J. Nelson, Eric Jones, Robert Kern, Eric Larson, CJ Carey, İlhan Polat, Yu Feng, Eric W. Moore, Jake VanderPlas, Denis Laxalde, Josef Perktold, Robert Cimrman, Ian Henriksen, E. A. Quintero, Charles R Harris, Anne M. Archibald, Antônio H. Ribeiro, Fabian Pedregosa, Paul van Mulbregt, and SciPy 1.0 Contributors.  
SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python.  
*Nature Methods*, 2020.
- [3] Michael Waskom, Olga Botvinnik, Drew O’Kane, Paul Hobson, Saulius Lukešas, David C Gemperline, Tom Augspurger, Yaroslav Halchenko, John B. Cole, Jordi Warmenhoven, Julian de Ruijter, Cameron Pye, Stephan Hoyer, Jake Vanderplas, Santi Villalba, Gero Kunter, Eric Quintero, Pete Bachant, Marcel Martin, Kyle Meyer, Alistair Miles, Yoav Ram, Tal Yarkoni, Mike Lee Williams, Constantine Evans, Clark Fitzgerald, Brian, Chris Fonnesbeck, Antony Lee, and Adel Qalieh.  
mwaskom/seaborn: v0.8.1 (september 2017), September 2017.
- [4] Stefan Fritsch, Frauke Guenther, Marvin N. Wright, Marc Suling, and Sebastian M. Mueller.  
*neuralnet: Training of Neural Networks*, 2019.  
R package version 1.44.2.
- [5] Joel Gombin Sebastian Jeworutzki Kent Russell Richard Zijdemann John Clouse Robin Lovelace Jannes Muenchow Martijn Tennekes, Jakub Nowosad.  
*tmap: Thematic Maps*, 2020.  
R package version 3.1.
- [6] Ricardo Abdiel Santana Ruiz.  
Proyecto delfin.  
<https://github.com/RASR-dot/Proyecto-Delfin>, 2020.